

# LAPORAN PROGRESS TUGAS BESAR

## PEMBELAJARAN MESIN

Klasifikasi Risiko Penyakit Jantung Menggunakan Algoritma Machine

Learning: Studi Komparatif

[Kesehatan dan Medis]



**Kelompok 11**

Rafly Taufika Fikri

11231083

# **BAB I PENDAHULUAN**

## **1.1. Latar Belakang & Tujuan**

Penyakit jantung merupakan penyebab kematian tertinggi secara global dengan angka kematian sekitar 17,9 juta jiwa per tahun berdasarkan data WHO. Deteksi dini menjadi tantangan utama karena gejala awalnya yang tidak spesifik sehingga seringkali baru teridentifikasi pada stadium lanjut. Proyek ini bertujuan membangun dan membandingkan beberapa model klasifikasi machine learning — Logistic Regression, Decision Tree, Random Forest, dan K-Nearest Neighbors — untuk memprediksi risiko penyakit jantung berdasarkan data klinis pasien secara otomatis dan lebih awal.

## **1.2. Dataset**

Dataset yang digunakan adalah Heart Failure Prediction Dataset yang bersumber dari Kaggle (<https://www.kaggle.com/datasets/fedesoriano/heart-failure-prediction>). Dataset ini terdiri dari 918 baris data dan 12 kolom (11 fitur klinis seperti usia, tekanan darah, kolesterol, dan hasil EKG, serta 1 label target berupa status penyakit jantung).

## **1.3. Paper Referensi Utama**

Proyek ini mengacu pada jurnal "Classification of Heart Failure Using Machine Learning: A Comparative Study" oleh Chulde-Fernández et al., yang diterbitkan di MDPI Life pada tahun 2025 (DOI: <https://doi.org/10.3390/life15030496>). Jurnal ini menjadi patokan metodologi eksperimen sekaligus tolok ukur performa model yang dikembangkan.

## **BAB II PROGRES PRA-PEMROSESAN DATA & EDA**

### **2.1. Pembersihan Data**

Pemeriksaan awal menggunakan `isnull().sum()` menunjukkan tidak ada missing values (NaN) eksplisit pada seluruh kolom dataset. Meskipun demikian, ditemukan anomali pada kolom Cholesterol yang memiliki sejumlah entri bernilai 0 — kondisi yang tidak mungkin terjadi secara medis. Nilai 0 ini tidak terdeteksi oleh pemeriksaan missing values standar karena bukan merupakan NaN, sehingga diperlakukan sebagai anomali domain-spesifik. Penanganannya dilakukan dengan mengganti seluruh nilai 0 pada kolom Cholesterol menggunakan nilai median dari sampel yang valid ( $\text{Cholesterol} > 0$ ). Median dipilih karena lebih robust terhadap distribusi data yang tidak simetris dibandingkan mean.


### **2.2. Transformasi Fitur**

Terdapat dua tahap transformasi yang diterapkan. Pertama, Label Encoding digunakan untuk mengonversi lima kolom kategorikal — Sex, ChestPainType, RestingECG, ExerciseAngina, dan ST\_Slope — menjadi representasi numerik, karena seluruh kolom tersebut bersifat nominal tanpa urutan yang inheren. Kedua, StandardScaler diterapkan untuk menstandarisasi seluruh fitur numerik sehingga memiliki mean = 0 dan standar deviasi = 1. Standarisasi ini krusial terutama untuk algoritma K-Nearest Neighbors yang berbasis perhitungan jarak, serta Logistic Regression yang menggunakan regularisasi. Sesuai praktik yang benar, scaler hanya di-fit pada data training kemudian di-transform pada data testing untuk mencegah data leakage.


### **2.3. Exploratory Data Analysis (EDA)**

Analisis distribusi kelas target menunjukkan dataset relatif seimbang dengan proporsi 55,3% kelas Heart Disease (1) dan 44,7% kelas Normal (0), rasio mendekati 1,24:1. Karena rasio ini masih dalam batas wajar, penanganan imbalanced data seperti SMOTE tidak diperlukan pada proyek ini. Stratified split tetap diterapkan pada proses pembagian data untuk memastikan proporsi kelas terjaga di kedua set.

Analisis korelasi menunjukkan bahwa fitur ST\_Slope, Oldpeak, ChestPainType, dan ExerciseAngina memiliki korelasi paling kuat terhadap variabel target HeartDisease. Sebaliknya, fitur RestingBP dan Cholesterol menunjukkan korelasi yang relatif lemah, yang mengindikasikan daya prediktif individualnya lebih terbatas dibandingkan fitur lainnya.



Gambar 3.1. Distribusi kelas target HeartDisease pada dataset.



Gambar 3.2. Heatmap korelasi antar fitur numerik terhadap variabel target.

## BAB III IMPLEMENTASI & EKSPERIMEN MODEL

### 3.1. Eksperimen Baseline

Pada tahap baseline, empat algoritma klasifikasi dilatih menggunakan parameter default dari scikit-learn. Pembagian data dilakukan dengan rasio 80% training dan 20% testing menggunakan stratified split. Keempat algoritma yang diuji adalah Logistic Regression, Decision Tree, K-Nearest Neighbors (KNN), dan Random Forest. Hasil metrik awal keempat model pada data testing adalah sebagai berikut :

| Algoritma           | Precision | Recall | F1-Score | AUC-ROC |
|---------------------|-----------|--------|----------|---------|
| Logistic Regression | 0.8491    | 0.8824 | 0.8654   | 0.8989  |
| Decision Tree       | 0.7980    | 0.7745 | 0.7861   | 0.7653  |
| K-Nearest Neighbors | 0.8654    | 0.8824 | 0.8738   | 0.9066  |
| Random Forest       | 0.8800    | 0.8627 | 0.8713   | 0.9258  |

### 3.2. Integrasi Metode Paper Referensi

Salah satu pendekatan yang ditekankan dalam jurnal referensi adalah penerapan seleksi fitur sebelum pelatihan model untuk menyaring fitur yang benar-benar informatif dan mengurangi noise. Teknik yang diadaptasi dari jurnal tersebut adalah seleksi fitur berbasis ANOVA F-test menggunakan SelectKBest dari scikit-learn. Setiap fitur dievaluasi berdasarkan hubungan statistiknya dengan label target melalui perhitungan F-score dan p-value. Fitur yang memiliki p-value di bawah 0,05 dianggap signifikan secara statistik dan dipertahankan, sementara fitur lainnya dieliminasi. Hasilnya, terpilih sebanyak 9 fitur dari total 11 fitur yang ada, yaitu ['Age', 'Sex', 'ChestPainType', 'RestingBP', 'FastingBS', 'MaxHR', 'ExerciseAngina', 'Oldpeak', 'ST\_Slope']. Teknik ini kemudian diintegrasikan ke dalam satu Pipeline bersama model Random Forest untuk memastikan seleksi fitur hanya di-fit pada data training, sehingga tidak terjadi data leakage

### 3.3. Optimasi & Hyperparameter Tuning

Optimasi hyperparameter dilakukan menggunakan GridSearchCV dengan stratified 5-fold cross-validation dan metrik scoring AUC-ROC. Proses tuning diterapkan pada dua model terbaik berdasarkan hasil baseline, yaitu Random Forest dan Logistic Regression.

Untuk Random Forest, parameter yang diuji meliputi :

- `n_estimators` : [100, 200, 300]
- `max_depth` : [None, 5, 10, 15]
- `min_samples_split` : [2, 5, 10]
- `min_samples_leaf` : [1, 2, 4]

Kombinasi parameter terbaik yang ditemukan adalah: `n_estimators` = 300, `max_depth` = 10, `min_samples_split` = 10, `min_samples_leaf` = 2, dengan CV AUC-ROC terbaik sebesar 0.9320.

Untuk Logistic Regression, parameter yang diuji meliputi :

- `C` : [0.001, 0.01, 0.1, 1, 10, 100]
- `penalty` : [l1, l2]
- `solver` : [liblinear, saga]

Kombinasi parameter terbaik yang ditemukan adalah: `C` = 0.1, `penalty` = l2 , `solver` = saga, dengan CV AUC-ROC terbaik sebesar 0.9141.

### 3.4. Tabel Komparasi Performa


| Algoritma                      | Precision | Recall | F1-Score | AUC-ROC |
|--------------------------------|-----------|--------|----------|---------|
| Logistic Regression (Baseline) | 0.8491    | 0.8824 | 0.8654   | 0.8989  |
| Decision Tree (Baseline)       | 0.7980    | 0.7745 | 0.7861   | 0.7653  |
| K-Nearest Neighbors            | 0.8654    | 0.8824 | 0.8738   | 0.9066  |

|                                   |        |        |        |        |
|-----------------------------------|--------|--------|--------|--------|
| (Baseline)                        |        |        |        |        |
| Random Forest<br>(Baseline)       | 0.8800 | 0.8627 | 0.8713 | 0.9258 |
| Random Forest<br>+ SelectKBest    | 0.8476 | 0.8725 | 0.8599 | 0.9152 |
| Logistic<br>Regression<br>(Tuned) | 0.8491 | 0.8824 | 0.8654 | 0.9003 |
| Random Forest<br>(Tuned)          | 0.8692 | 0.9118 | 0.8900 | 0.9271 |

Berdasarkan tabel di atas, Random Forest (Tuned) secara konsisten mengungguli seluruh model lainnya pada hampir semua metrik evaluasi, khususnya pada AUC-ROC yang menunjukkan kemampuan terbaik dalam membedakan kelas positif dan negatif. Sejalan dengan tren pada paper referensi, Random Forest tetap menjadi salah satu model terbaik meskipun nilai AUC pada penelitian ini sedikit lebih rendah, di mana Random Forest juga mencatatkan performa tertinggi dengan AUC sebesar 0,97.

Meskipun peningkatan AUC kecil, tuning parameter meningkatkan kualitas probabilistic ranking, namun threshold klasifikasi default 0.5 menyebabkan precision/recall relatif sama.

Seleksi fitur tidak meningkatkan performa karena Random Forest secara alami telah mampu melakukan implicit feature selection. Penghapusan beberapa fitur justru mengurangi informasi prediktif.



*Gambar 3.3 Kurva ROC seluruh model baseline dan tuned pada data testing.*

## **BAB IV KENDALA TEKNIS & ANALISIS ERROR**

### **4.1. Kendala Teknis**

Selama proses pengembangan model klasifikasi risiko penyakit jantung, terdapat beberapa kendala teknis yang ditemui pada tahap pra-pemrosesan data, pelatihan model, maupun evaluasi performa. Kendala utama yang dihadapi adalah sebagai berikut :

- Meskipun dataset tidak memiliki missing values secara eksplisit, ditemukan sejumlah nilai tidak wajar pada kolom Cholesterol, yaitu bernilai 0. Secara medis, nilai kolesterol 0 tidak realistis sehingga berpotensi menurunkan kualitas model apabila langsung digunakan sebagai data valid.
- Pada eksperimen awal, model Decision Tree menunjukkan performa training yang tinggi namun performa testing lebih rendah dibanding model lain. Hal ini mengindikasikan kecenderungan model menghafal pola data latih (overfitting) dan kurang mampu melakukan generalisasi pada data baru.
- Teknik seleksi fitur menggunakan SelectKBest (ANOVA F-test) awalnya diharapkan meningkatkan performa model. Namun pada hasil eksperimen, kombinasi Random Forest + SelectKBest justru menghasilkan nilai AUC-ROC sedikit lebih rendah dibanding Random Forest baseline.
- Proses pencarian parameter terbaik menggunakan GridSearchCV membutuhkan waktu komputasi lebih lama dibanding pelatihan model biasa, terutama pada Random Forest karena banyak kombinasi parameter yang diuji melalui 5-fold cross validation.
- Pada awal implementasi, terdapat tantangan dalam memastikan proses scaling dan feature selection hanya dilakukan pada data training. Jika preprocessing diterapkan sebelum train-test split, maka informasi data testing dapat bocor ke model dan menyebabkan evaluasi menjadi bias.

#### 4.2. Upaya Solusi

Untuk mengatasi berbagai kendala tersebut, beberapa langkah perbaikan telah dilakukan sebagai berikut :

- Nilai 0 pada kolom Cholesterol diganti menggunakan median dari data valid (nilai  $> 0$ ). Median dipilih karena lebih robust terhadap outlier dibanding rata-rata.
- Dilakukan pembatasan kompleksitas model melalui pengaturan parameter seperti `max_depth`, `min_samples_split`, dan `min_samples_leaf`. Selain itu, model ensemble seperti Random Forest digunakan karena lebih stabil dibanding Decision Tree tunggal.
- Hasil SelectKBest tetap dicantumkan sebagai bagian eksperimen, namun tidak dijadikan model final karena performanya lebih rendah. Hal ini menjadi temuan bahwa Random Forest telah mampu melakukan seleksi fitur internal secara otomatis.
- Ruang pencarian parameter dibatasi pada kombinasi yang paling relevan agar waktu tuning tetap efisien. Selain itu, digunakan `n_jobs=-1` pada GridSearchCV agar komputasi berjalan paralel menggunakan seluruh core CPU yang tersedia.
- Untuk mencegah data leakage, preprocessing seperti scaling dan feature selection diintegrasikan ke dalam Pipeline scikit-learn, sehingga seluruh proses fitting hanya dilakukan pada data training dalam setiap fold cross-validation.

#### 4.3. Analisis Error

Berdasarkan evaluasi confusion matrix dan metrik klasifikasi, kesalahan prediksi yang masih muncul umumnya terjadi pada sampel dengan karakteristik borderline atau memiliki nilai fitur yang mirip antara kelas normal dan kelas berisiko penyakit jantung. Hal ini menunjukkan bahwa beberapa kasus medis memang sulit dipisahkan secara tegas hanya berdasarkan fitur klinis dasar.

Selain itu, dataset yang digunakan memiliki jumlah sampel relatif terbatas (918 data), sehingga variasi pola pasien nyata kemungkinan belum sepenuhnya terwakili. Oleh karena itu, peningkatan performa di masa depan berpotensi dicapai melalui penambahan dataset yang lebih besar dan lebih beragam.

## **BAB V HASIL & PEMBAHASAN**

Sebagai tahap lanjutan menuju Final Demo (UAS) pada Pertemuan 16, fokus utama adalah melakukan finalisasi sistem prediksi risiko penyakit jantung agar tidak hanya berhenti pada tahap eksperimen model, tetapi juga siap digunakan dalam bentuk demonstrasi aplikasi sederhana. Rencana tindak lanjut disusun secara bertahap mulai dari penyempurnaan pipeline, deployment model, hingga penyusunan laporan akhir.

### **5.1. Minggu 14 – Finalisasi Pipeline Machine Learning**

Pada tahap ini, seluruh proses yang sebelumnya masih terpisah dalam notebook akan dirapikan menjadi satu alur kerja machine learning yang utuh dan terstruktur. Pipeline akan mencakup seluruh tahapan mulai dari input data mentah, preprocessing, prediksi model, hingga output hasil klasifikasi.

Komponen pipeline yang akan difinalisasi meliputi :

- Pembersihan data (penanganan nilai anomali pada kolom Cholesterol)
- Encoding fitur kategorikal
- Feature scaling menggunakan StandardScaler
- Feature selection (jika digunakan pada model final)
- Model terbaik hasil eksperimen, yaitu Random Forest Tuned
- Fungsi prediksi untuk data pasien baru

Tujuan tahap ini adalah memastikan seluruh proses dapat berjalan otomatis tanpa perlu menjalankan cell notebook satu per satu.

Output yang ditargetkan :

- File Python utama (main.py) atau notebook final yang rapi
- Pipeline siap digunakan ulang
- Struktur folder proyek lebih terorganisasi

### **5.2. Minggu 14 – Penyimpanan Model Terbaik**

Setelah model final dipastikan stabil, model akan disimpan agar dapat digunakan kembali tanpa perlu proses training ulang. Penyimpanan model dilakukan menggunakan pustaka Joblib atau Pickle. Langkah ini penting karena pada saat demo, model cukup dimuat (load) lalu langsung digunakan untuk prediksi secara real-time.

Contoh file yang akan dibuat :

- heart\_model.pkl
- scaler.pkl
- encoder.pkl
- pipeline.pkl

Manfaat :

- Mempercepat proses demo
- Menghindari training ulang setiap kali program dijalankan
- Memudahkan integrasi ke aplikasi Streamlit

### 5.3. Minggu 15 – Pembuatan Antarmuka Pengguna (UI) dengan Streamlit

Agar proyek lebih aplikatif dan menarik saat presentasi, kelompok berencana membangun antarmuka sederhana menggunakan Streamlit. Aplikasi ini memungkinkan pengguna memasukkan data pasien melalui form, kemudian sistem menampilkan hasil prediksi secara langsung.

Fitur utama UI yang direncanakan :

- Age
- Sex
- ChestPainType
- RestingBP
- Cholesterol
- FastingBS
- MaxHR
- ExerciseAngina
- Oldpeak
- ST\_Slope

Output Sistem :

- Prediksi Risiko Penyakit Jantung / Normal
- Probabilitas risiko (%)
- Penjelasan singkat hasil prediksi

#### 5.4. Minggu 15 – Pengujian dan Simulasi Final Demo

Sebelum presentasi UAS, sistem akan diuji secara menyeluruh untuk memastikan tidak ada error saat demonstrasi. Pengujian dilakukan pada beberapa skenario input berbeda.

Tahapan pengujian :

- Input pasien normal → hasil normal
- Input pasien berisiko tinggi → hasil positif
- Validasi semua tombol UI berjalan baik
- File model dapat di-load tanpa error
- Waktu prediksi cepat ( $< 2$  detik)

Selain pengujian teknis, kelompok juga akan melakukan simulasi presentasi agar penyampaian saat demo lebih terstruktur.

#### 5.5. Minggu 16 – Finalisasi Laporan dan Presentasi

Pada tahap akhir, seluruh dokumentasi proyek akan dirapikan menjadi laporan final.

Bagian yang akan disempurnakan meliputi :

- Pendahuluan
- Metodologi
- Hasil eksperimen
- Evaluasi model
- Screenshot aplikasi
- Kesimpulan
- Daftar pustaka
- Lampiran source code / GitHub

#### 5.6. Target Akhir Proyek

Pada saat Final Demo, kelompok menargetkan dapat menampilkan sistem prediksi risiko penyakit jantung yang :

- Menggunakan model machine learning terbaik hasil eksperimen
- Memiliki antarmuka yang mudah digunakan
- Dapat melakukan prediksi secara real-time
- Menunjukkan penerapan nyata machine learning pada bidang kesehatan

Dengan demikian, proyek tidak hanya berhenti sebagai eksperimen akademik, tetapi berkembang menjadi prototype sistem cerdas yang siap didemonstrasikan secara langsung

## **BAB VI LAMPIRAN**

### 6.1. Link

Link Repositori :

Link Google Colab :

<https://colab.research.google.com/drive/1RucWrJG77tmAgz9OhrA6hW0lPofPVuiG?usp=sharing>